



DATA SCIENCE

INTRODUCTION

OUTLINE

Definition of Data Science

Data Science as an multi-disciplinary field

Data Science Life Cycle

Data Science Tasks

Data Science Tools

DEFINITION

Data Science is a study which deals with *identification*, *representation* and *extraction* of meaningful information (*knowledge*) from **data sources** to be used for **business purposes**.

علم البيانات هو دراسة تتعامل مع تحديد وتمثيل واستخراج معلومات ذات مغزى (معرفة) من مصادر البيانات لاستخدامها في الأغراض التجارية.

DATA SOURCES

Data is everywhere and **still growing**.

The amount of digital data that exists **is growing at a rapid rate**, doubling every two years, and changing the way we live.

Data is growing faster than ever before and by the year 2020, about 1.7 megabytes of new information will be created every second for every human being on the planet.

البيانات في كل مكان ولا تزال تنمو.

كمية البيانات الرقمية الموجودة تتزايد بسرعة
تتضاعف كل عامين وتغير طريقة عيشنا.

تنمو البيانات بشكل أسرع من أي وقت مضى وبحلول عام 2020 ، سيتم إنشاء حوالي 1.7 ميغابايت من المعلومات الجديدة كل ثانية لكل إنسان على هذا الكوكب.



DATA NEVER SLEEPS 3.0

How much data is generated **every minute?**

Data is being created all the time without us even noticing it. Much of what we do every day now happens in the digital realm, leaving an ever-increasing digital trail that can be measured and analyzed. Just how much data do our tweets, likes and photo uploads really generate? For the third time, Domo has the answer—and the numbers are staggering.



THE GLOBAL INTERNET POPULATION GREW **18.5%** FROM 2013–2015 AND NOW REPRESENTS

3.2 BILLION PEOPLE.

BUSINESS PURPOSES أغراض الأعمال

Having knowledge from such data helps organizations to:

- be efficient in terms of cost, delivery and productivity;
- identifies new opportunities, and
- creates a strong brand image of the organization

تساعد المعرفة من هذه البيانات المؤسسات على:
أن تكون فعالة من حيث التكلفة والتسليم والإنتاجية ؛
يحدد الفرص الجديدة ، و

يخلق صورة قوية للعلامة التجارية للمؤسسة

WHY DATA SCIENCE, AND WHY NOW?

To answer this there are three main reasons:

1. New technology makes it possible to capture, annotate, and store vast amounts of databases in organization, social media, logging, and sensor data.
 - After having all these data, we begin to wonder what you can do with it.

للإجابة على هذا هناك ثلاثة أسباب رئيسية:
1. تتيح التكنولوجيا الجديدة إمكانية التقاط كميات هائلة من قواعد البيانات في المؤسسة والتعليق عليها وتخزينها والوسائط الاجتماعية والتسجيل وبيانات الاستشعار. بعد الحصول على كل هذه البيانات ، بدأنا في التساؤل عما يمكنك فعله بها.

WHY DATA SCIENCE, AND WHY NOW?

To answer this there are three main reasons:

2. Computing advances make it possible to analyse data in novel ways and increased scales.

- Cloud computing architectures give us an access to vast power when we need it.
- Machine Learning new approaches lead to amazing advances in well-known problems, like Computer Vision and Natural Language Processing.

للإجابة على هذا هناك ثلاثة أسباب رئيسية:

2. يجعل التقدم الحوسبي من الممكن تحليل البيانات بطرق جديدة ومقاييس متزايدة. تمنحنا هياكل الحوسبة السحابية إمكانية الوصول إلى قوة هائلة عندما نحتاج إليها. تؤدي مناهج التعلم الآلي الجديدة إلى تطورات مذهلة في المشكلات المعروفة ، مثل رؤية الكمبيوتر ومعالجة اللغة الطبيعية.

WHY DATA SCIENCE, AND WHY NOW?

To answer this there are three main reasons:

3. Famous technology companies, like Google and Facebook, **have proven** the **power of modern data analytics**.
 - Success stories applying data to such diverse areas as business , management , sports management, and election forecasting have served as role models to bring data science to a large popular audience.

للإجابة على هذا هناك ثلاثة أسباب رئيسية:

، قوة تحليلات البيانات Facebook و Google أثبتت شركات التكنولوجيا الشهيرة ، مثل الحديثة.

عملت قصص النجاح التي طبقت البيانات على مجالات متنوعة مثل الأعمال والإدارة وإدارة الرياضة والتنبؤ بالانتخابات كنماذج يحتذى بها لجلب علم البيانات إلى جمهور عريض من الجمهور.

DEFINITION

Data Science is the science which uses computer science, statistics and machine learning, visualization and human-computer interactions to collect, clean, integrate, analyze, visualize, interact with data to create data products.

علم البيانات هو العلم الذي يستخدم علوم الكمبيوتر والإحصاءات والتعلم الآلي والتصور والتفاعلات بين الإنسان والحاسوب لجمع البيانات وتنظيفها ودمجها وتحليلها وتصورها والتفاعل معها لإنشاء منتجات البيانات.

DATA PRODUCTS

Data Science – development of data product

A "data product" is a technical asset that: (1) utilizes data as input, and (2) processes that data to return algorithmically-generated results.

A data product embeds that algorithm in a web site so that users can input values and get predictions.

The classic example of a data product is a recommendation engine, which ingests user data, and makes personalized recommendations based on that data.

علم البيانات - تطوير منتج البيانات
"منتج البيانات" هو أصل تقني: (1) يستخدم البيانات كمدخلات ، و (2) يعالج تلك البيانات لإرجاع النتائج التي تم إنشاؤها بواسطة الخوارزميات.
يقوم منتج البيانات بتضمين هذه الخوارزمية في موقع ويب بحيث يمكن للمستخدمين إدخال القيم والحصول على تنبؤات.
المثال الكلاسيكي لمنتج البيانات هو محرك التوصيات ، الذي يستوعب بيانات المستخدم ، ويقدم توصيات مخصصة بناءً على تلك البيانات.

EXAMPLES OF DATA PRODUCTS

Amazon's **recommendation engines**, **is a data product**, suggest items to buy.

- Netflix and Spotify recommends movies and music respectively.

Gmail's **spam filter**, **is a data product**, processes incoming mail and determines if a message is junk or not.

Computer vision used for self-driving cars, **is a data product**, machine learning algorithms are able to recognize traffic lights, other cars on the road, and pedestrians.

محركات توصية Amazon، هي منتج بيانات، تقترح عناصر للشراء.
يقترح Netflix و Spotify الأفلام والموسيقى
على التوالي.

فلتر البريد العشوائي في Gmail، هو بيانات منتج، يعالج الوارد
البريد ويحدد ما إذا كانت الرسالة غير مهمة أم لا.

الرؤية الحاسوبية المستخدمة للسيارات ذاتية القيادة هي منتج بيانات وخوارزميات التعلم الآلي قادرة
على التعرف على إشارات المرور والسيارات الأخرى على الطريق والمشاة.

OUTLINE

Definition of Data Science

Data Science as an multi-disciplinary field

Data Science Life Cycle

Data Science Tasks

Data Science Tools

DATA SCIENCE AS MULTI- DISCIPLINARY FIELD

Data Science is a **multi-disciplinary** field.

Data Science is the science which uses *computer science*, *statistics* and *machine learning*, *visualization* and *human-computer interactions* to *collect*, *clean*, *integrate*, *analyze*, *visualize*, *interact* with data to create **data products**.

Data Science employs techniques and theories drawn from many fields within the broad areas computer science, mathematics, statistics, data engineering, visualization, predictive analytics, uncertainty modelling, data warehousing and high performance computing.


علم البيانات هو مجال متعدد التخصصات.

علم البيانات هو العلم الذي يستخدم علوم الكمبيوتر والإحصاءات والتعلم الآلي والتصور والتفاعلات بين الإنسان والحاسوب لجمع البيانات وتنظيمها ودمجها وتحليلها وتصورها والتفاعل معها لإنشاء منتجات البيانات.

يستخدم علم البيانات تقنيات ونظريات مستمدة من العديد من المجالات في مجالات واسعة من علوم الكمبيوتر والرياضيات والإحصاء وهندسة البيانات والتصور والتحليلات التنبؤية ونمذجة عدم اليقين وتخزين البيانات والحوسبة عالية الأداء.

DATA SCIENCE AS MULTI-DISCIPLINARY FIELD

Data Science Venn Diagram v2.0



Copyright © 2014 by Steven Geringer Raleigh, NC.
Permission is granted to use, distribute, or modify this
image, provided that this copyright notice remains intact

DATA SCIENCE AS MULTIDISCIPLINARY FIELD



DATA SCIENCE AS MULTIDISCIPLINARY FIELD

Data Science is subset of **computer science** where the study of data is done by using different methods and technology.

- Like Hadoop, relational and NoSQL databases

علم البيانات هو مجموعة فرعية من علوم الكمبيوتر حيث تتم دراسة البيانات باستخدام طرق وتقنيات مختلفة.

مثل Hadoop وقواعد البيانات العلائقية و NoSQL

DATA SCIENCE AS MULTIDISCIPLINARY FIELD

Some data science methods comes from **statistics** such as Naïve Baiys and Maximum Entropy and also used for estimating probabilities of predictions.

Data science is differ than **statistics** in kind of data (not only numerical) , kinds of methods (mostly use machine learning methods) , more than one hypotheses, amount of data (statistics uses samples)

تأتي بعض طرق علم البيانات من الإحصائيات مثل Naïve Baiys و Maximum Entropy وتستخدم أيضاً لتقدير احتمالات التنبؤات.

يختلف علم البيانات عن الإحصائيات في نوع البيانات (ليس فقط العددية) ، وأنواع الأساليب (تستخدم في الغالب أساليب التعلم الآلي) ، وأكثر من فرضية واحدة ، وكمية البيانات (تستخدم الإحصائيات عينات)

DATA SCIENCE AS MULTIDISCIPLINARY FIELD

Machine Learning focuses on complex representations and search methods for specialized data-intensive problems.

Data Science uses methods from Machine Learning such as Decision Tree and Neural Nets.

Machine Learning uses samples and Data Science uses whole data.

(Big Data) Data Science can access data from database. Machine Learning some times used to replace human where Data Mining to help human.

يركز التعلم الآلي على التمثيلات المعقدة وطرق البحث للمشكلات المتخصصة كثيفة البيانات.

يستخدم علم البيانات طرقًا من التعلم الآلي مثل شجرة القرار والشبكات العصبية.

يستخدم التعلم الآلي العينات ويستخدم علم البيانات البيانات الكاملة.

(البيانات الكبيرة) يمكن لعلم البيانات الوصول إلى البيانات من قاعدة البيانات. يستخدم التعلم الآلي في بعض الأحيان ليحل محل الإنسان حيث يتم تعدين البيانات لمساعدة الإنسان.

DATA SCIENCE AS MULTIDISCIPLINARY FIELD

Databases part of Data Science that provide the fast and reliable access to data. Databases used for data operation (Storing and retrieving data), Data Science for Decision making.

قواعد البيانات جزء من Data Science التي توفر وصولاً سريعاً وموثوقاً إلى البيانات. قواعد البيانات المستخدمة لتشغيل البيانات (تخزين البيانات واسترجاعها) ، علم البيانات لاتخاذ القرار.

DATA SCIENCE AS MULTIDISCIPLINARY FIELD

	Databases	Data Science
Data Value	“Expensive”	“Cheap”
Data Volume	Modest	Massive
Examples	Bank records, Personnel records, Census, Medical records	Online clicks, GPS logs, Tweets, Building sensor readings
Priorities	Consistency, Error recovery, Auditability	Speed, Availability, Query richness
Structured	Strongly (Schema)	Weakly or none (Text)
Recognition	SQL	NoSQL: MongoDB, CouchDB, Hbase, Cassandra, Riak, Memcached, Apache River, ...

DATA SCIENCE AS MULTIDISCIPLINARY FIELD

Visualization representing data in a visual form.

- This visual form can be a chart, graphs, lists or a map etc.

This representation helps people to understand the magnitude of the data.


It is used to gain visual insights into the structure of the data.

Visualization is in large quantities used as a pre- and post-processing tool for Data Science .

التصور الذي يمثل البيانات في شكل مرئي.
يمكن أن يكون هذا النموذج المرئي مخططاً أو رسوماً بيانية أو قوائم أو خريطة وما إلى ذلك.
هذا التمثيل يساعد الناس على فهم
حجم البيانات.
يتم استخدامه لاكتساب رؤية بصرية في بنية البيانات.

يتم استخدام التصور بكميات كبيرة كأداة ما قبل المعالجة وبعدها لعلوم البيانات.

DATA SCIENCE AS MULTI-DISCIPLINARY FIELD



OUTLINE

Definition of Data Science

Data Science as an multi-disciplinary field

Data Science Life Cycle


Data Science Tasks


Data Science Tools

DATA SCIENCE LIFECYCLE

The data science life cycle is the sequence of stages that a data scientist goes through from its initial generation or capture to the end of its project.

دورة حياة علم البيانات هي تسلسل المراحل التي يمر بها عالم البيانات من إنشائها الأولي أو التقاطها حتى نهاية مشروعه.





DATA SCIENCE LIFECYCLE

1. BUSINESS UNDERSTANDING

To obtain the highest benefit from data science, there must be a clear **Business Understanding**

Business Understanding: Understand the project objectives and requirements from a business perspective.

Before we even begin doing anything with “Data Science”, we must first take into consideration what problem we’re trying to solve.

- The data scientists keep asking what and why to ensure that every decision made in the company is supported by concrete data, and that it is guaranteed (with a high probability) to achieve results.

فهم الأعمال
للحصول على أعلى فائدة من علم البيانات ، يجب أن يكون هناك فهم تجاري واضح
فهم الأعمال: فهم أهداف ومتطلبات المشروع من منظور الأعمال.
قبل أن نبدأ في فعل أي شيء مع "علوم البيانات" ، يجب علينا أولاً أن نأخذ في الاعتبار المشكلة
التي نحاول حلها.

يستمر علماء البيانات في التساؤل عن ماذا ولماذا للتأكد من أن كل قرار يتم اتخاذه في الشركة
مدعوم ببيانات ملموسة ، وأنه مضمون (مع احتمال كبير) لتحقيق النتائج.

DATA SCIENCE LIFECYCLE

1. BUSINESS UNDERSTANDING

Example of Goal for business company are:

- You want to attract new customers
- You want to avoid high-risk customers
- You want to understand the characteristics of your current customers?
- You want to make your unprofitable customers more profitable?
- You want to retain your profitable customers?
- You want to win back your lost customers?
- You want to improve customer satisfaction?
- You want to increase sales?
- You want to reduce expenses

DATA SCIENCE LIFECYCLE

1. BUSINESS UNDERSTANDING

We typically use data science to answer five types of questions:

- How much or how many? (**regression**)
- Which category? (**classification**)
- Which group? (**clustering**)
- Is this weird? (**anomaly detection**)
- Which option should be taken? (**recommendation**)

نستخدم علم البيانات عادةً للإجابة على خمسة أنواع من الأسئلة:

كم أو كم واحد؟ (تراجع)

أي فئة؟ (تصنيف)

أي مجموعة؟ (تجمع)

هل هذا غريب؟ (إكتشاف عيب خلقي)

أي خيار يجب أن يؤخذ؟ (توصية)

DATA SCIENCE LIFECYCLE

2. OBTAIN DATA

We cannot do anything as a data scientist without having data.

As a rule of thumb, there are some things we must take into consideration when obtaining data.

We must identify all the available datasets, which can be from the internet or external/internal databases, that related to the project.

You must extract the data into a usable format

- csv, json, xml, etc..

الحصول على البيانات

لا يمكننا فعل أي شيء كعالم بيانات بدون وجود بيانات.

كقاعدة عامة ، هناك بعض الأشياء التي يجب أن نأخذها في الاعتبار

الاعتبار عند الحصول على البيانات.

يجب أن نحدد جميع مجموعات البيانات المتاحة ، والتي يمكن أن تكون من الإنترنت أو قواعد بيانات خارجية / داخلية ، والتي تتعلق بالمشروع.

يجب عليك استخراج البيانات إلى تنسيق قابل للاستخدام

csv ، json ، xml ، إلخ.

DATA SCIENCE LIFECYCLE

2. OBTAIN DATA

At this stage, some of the questions worth considering are:

What data do I need for my project?

Where does it live? How
can I obtain it?

What is the most efficient way to store and access all of it?

2. الحصول على البيانات

في هذه المرحلة ، بعض الأسئلة التي تستحق الدراسة هي: ما البيانات التي أحتاجها لمشروعي؟
اين يسكن؟ كيف يمكنني الحصول عليها؟

ما هي الطريقة الأكثر فعالية لتخزينه والوصول إليه؟

DATA SCIENCE LIFECYCLE

2. OBTAIN DATA

Skills Required:

Database Management: MySQL, PostgreSQL, MongoDB

Querying Relational Databases

Retrieving Unstructured Data: text, videos, audio files, documents

Distributed Storage: Hadoops, Apache Spark/Flink

2. الحصول على البيانات

المهارات المطلوبة:

إدارة قواعد البيانات: MySQL و PostgreSQL و MongoDB

الاستعلام عن قواعد البيانات العلائقية

استرجاع البيانات غير المهيكلة: نصوص ، فيديوهات ، ملفات صوتية ،

مستندات

التخزين الموزع: Hadoops ، Apache Spark / Flink

DATA SCIENCE LIFECYCLE

3. CLEANING DATA

Data can be corrupted with various errors such as missing, incorrect, or inconsistent values.

This phase require the most time and effort. Because the results and output of your machine learning model is only as good as what you put into it. Basically, garbage in garbage out.

This process can often take 50 to 80 percent of their time.

3. تنظيف البيانات

يمكن أن تتلف البيانات مع وجود العديد من الأخطاء مثل القيم المفقودة أو غير الصحيحة أو غير المتسقة.

هذه المرحلة تتطلب معظم الوقت والجهد. لأن نتائج ومخرجات نموذج التعلم الآلي الخاص بك جيدة بقدر ما تضعه فيه. في الأساس ، القمامة في القمامة. غالبًا ما تستغرق هذه العملية من 50 إلى 80 بالمائة من وقتهم.

DATA SCIENCE LIFECYCLE

3. CLEANING DATA

The reason why this is such a time consuming process is simply because there are so many possible scenarios that could necessitate cleaning.

For instance, the data could also have inconsistencies within the same column, meaning that some rows could be labelled 0 or 1, and others could be labelled no or yes.

السبب في أن هذه العملية تستغرق وقتاً طويلاً هو ببساطة لأن هناك العديد من السيناريوهات المحتملة التي قد تتطلب التنظيف.

على سبيل المثال ، قد تحتوي البيانات أيضاً على تناقضات داخل نفس العمود ، مما يعني أن بعض الصفوف يمكن أن تكون كذلك المسماة 0 أو 1 ، والبعض الآخر يمكن تصنيفها لا أو نعم.

DATA SCIENCE LIFECYCLE

3. CLEANING DATA

The data types could also be inconsistent - some of the 0s might integers, whereas some of them could be strings. If we're dealing with a categorical data type with multiple categories, some of the categories could be misspelled or have different cases, such as having categories for both male and Male. .

3. تنظيف البيانات

قد تكون أنواع البيانات أيضًا غير متناسقة - قد تكون بعض الأصفار أعدادًا صحيحة ، في حين أن بعضها قد يكون سلاسل. إذا كنا نتعامل مع نوع بيانات فئوي بفئات متعددة ، فقد تكون بعض الفئات بها أخطاء إملائية أو بها حالات مختلفة ، مثل وجود فئات لـ كلا من الذكور والإناث. .

DATA SCIENCE LIFECYCLE

3. CLEANING DATA

One of the steps that is often forgotten in this stage, causing a lot of problems later on, is the presence of **missing data**.

Missing data can throw a lot of errors in the model creation and training.

Transform the data into a form appropriate for given data mining method

Data is transformed or consolidated into forms appropriate for mining

3. تنظيف البيانات

إحدى الخطوات التي غالبًا ما يتم نسيانها في هذه المرحلة ، والتي تسبب الكثير من المشاكل لاحقًا ، هي وجود بيانات مفقودة.

يمكن أن تؤدي البيانات المفقودة إلى حدوث الكثير من الأخطاء في إنشاء النموذج والتدريب.

تحويل البيانات إلى نموذج مناسب لطريقة التنقيب عن البيانات المحددة

يتم تحويل البيانات أو دمجها في أشكال مناسبة

للتعدين

DATA SCIENCE LIFECYCLE

4. DATA EXPLORATION

The data exploration stage is like the brainstorming of data analysis. This is where you understand the patterns and bias in your data.

It could involve plotting a histogram or distribution curve to see the general trend, or even creating an interactive visualization that lets you dive down into each data point and explore the story behind the outliers.

4. استكشاف البيانات

تشبه مرحلة استكشاف البيانات عملية العصف الذهني لتحليل البيانات. هذا هو المكان الذي تفهم فيه الأنماط والتحيز في بياناتك.

يمكن أن يتضمن تخطيط الرسم البياني أو منحني التوزيع لمعرفة الاتجاه العام ، أو حتى إنشاء تصور تفاعلي يتيح لك الغوص في كل نقطة بيانات واستكشاف القصة وراء القيم المتطرفة.



DATA SCIENCE LIFECYCLE

4. DATA EXPLORATION

This histogram shows the number of customers of different ages and quickly tells the viewer that the majority of customers are over the age of 50

4. استكشاف البيانات

يوضح هذا الرسم البياني عدد العملاء من مختلف الأعمار ويخبر المشاهد بسرعة أن غالبية العملاء تزيد أعمارهم عن 50 عامًا



DATA SCIENCE LIFECYCLE

4. DATA EXPLORATION

Using all of this information, you start to form hypotheses about your data and the problem you are tackling. If you were predicting student scores for example, you could try visualizing the relationship between scores and sleep.

4. استكشاف البيانات

باستخدام كل هذه المعلومات ، تبدأ في تكوين فرضيات حول بياناتك والمشكلة التي تعالجها. إذا كنت تتوقع درجات الطالب على سبيل المثال ، فيمكنك محاولة تصور العلاقة بين النتائج والنوم.

LIFECYCLE

5. FEATURE ENGINEERING

In machine learning, a feature is a measurable property or attribute of a phenomenon being observed

5. ميزة الهندسة

في التعلم الآلي ، الميزة هي خاصية قابلة للقياس أو سمة لظاهرة يتم ملاحظتها

Attributes

<i>Tid</i>	<i>Refund</i>	<i>Marital Status</i>	<i>Taxable Income</i>	<i>Cheat</i>
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Objects


Class

DATA SCIENCE LIFECYCLE

5. FEATURE ENGINEERING

Feature selection is the process of cutting down the features that add more noise than information.

اختيار الميزة هو عملية تقليل الميزات التي تضيف ضوضاء أكثر من المعلومات.



DATA SCIENCE LIFECYCLE

5. FEATURE ENGINEERING

If we were predicting the scores of a student, a possible feature is the amount of sleep they get.

In more complex prediction tasks such as character recognition, features could be histograms counting the number of black pixels.

إذا كنا نتوقع درجات الطالب ، فإن الميزة المحتملة هي مقدار النوم الذي يحصل عليه.

في مهام التنبؤ الأكثر تعقيدًا مثل التعرف على الأحرف ، يمكن أن تكون الميزات عبارة عن رسوم بيانية تحسب عدد وحدات البكسل السوداء.

DATA SCIENCE LIFECYCLE

5. FEATURE ENGINEERING

Feature construction involves creating new features from the ones that you already have.

For example, if you have a feature for age, but your model only cares about if a person is an adult or minor, you could threshold it at 18, and assign different categories to instances above and below that threshold.

يتضمن بناء الميزات إنشاء ميزات جديدة من الميزات التي لديك بالفعل.

على سبيل المثال ، إذا كانت لديك ميزة تتعلق بالعمر ، ولكن لا يهتم نموذجك إلا إذا كان الشخص بالغاً أو قاصراً ، فيمكنك تحديدها عند 18 ، وتعيين فئات مختلفة لمثيلات أعلى وأدنى من هذا الحد.

DATA SCIENCE LIFECYCLE

5. FEATURE ENGINEERING

You could also **merge multiple features** to make them more informative by taking their sum, difference or product.

For example, if you were predicting student scores and had features for the number of hours of sleep on each night, you might want to create a feature that denoted the average sleep that the student had instead.

يمكنك أيضاً دمج ميزات متعددة لجعلها أكثر إفادة من خلال أخذ مجموعها أو فرقها أو منتجها.

على سبيل المثال ، إذا كنت تتوقع درجات الطالب ولديك ميزات لعدد ساعات النوم في كل ليلة ، فقد ترغب في إنشاء ميزة تشير إلى متوسط النوم الذي كان ينام على الطالب بدلاً من ذلك.

DATA SCIENCE LIFECYCLE

6. MODELLING

Modelling is where the machine learning finally comes into the data science project.

- Based on the questions data scientist asked in the business understanding stage, this is where they decide which model to pick for their problem.

data scientist will have access to many algorithms and use them to accomplish different business goals.

For types of modeling see next section

النمذجة

النمذجة هي المكان الذي يأتي فيه التعلم الآلي أخيرًا في مشروع علم البيانات. بناءً على الأسئلة التي طرحها عالم البيانات في مرحلة فهم الأعمال ، هذا هو المكان الذي يقررون فيه النموذج الذي يختارونه لمشكلتهم.

سيتمكن عالم البيانات من الوصول إلى العديد من الخوارزميات واستخدامها لتحقيق أهداف العمل المختلفة.

لمعرفة أنواع النمذجة انظر القسم التالي

DATA SCIENCE LIFECYCLE


7. INTERPRETING (DATA VISUALIZATION)

The most important step is to understand and learn how to explain your findings through communication.

People aren't going to magically understand your findings. The best way to make an impact is telling your story through visualization.

أهم خطوة هي فهم وتعلم كيفية شرح نتائجك من خلال التواصل.

لن يفهم الناس نتائجك بطريقة سحرية. أفضل طريقة لإحداث تأثير هو سرد قصتك من خلال التخيل.



DATA SCIENCE LIFECYCLE

8. BUSINESS UNDERSTANDING

Now that you've gone through the entire lifecycle, it's time to go back to the drawing board.

Remember, this is a cycle, and so it's an iterative process. This is where you evaluate how the success of your model relates to your original business understanding.

Does it tackle the problems identified? Does the analysis yield any tangible solutions?

If you encountered any new knowledge during the first iteration of the lifecycle, you can now use that knowledge into the next iteration to generate even more powerful insights.

8. فهم الأعمال

الآن بعد أن انتهيت من دورة الحياة بأكملها ، حان الوقت للعودة إلى لوحة الرسم.

تذكر أن هذه دورة ، وبالتالي فهي عملية تكرارية. هذا هو المكان الذي تقيم فيه مدى نجاح نموذجك يتعلق بفهم عملك الأصلي.

هل يعالج المشاكل المحددة؟ هل يسفر التحليل عن أي حلول ملموسة؟

إذا واجهت أي معرفة جديدة أثناء التكرار الأول لدورة الحياة ، فيمكنك الآن استخدام هذه المعرفة في التكرار التالي لتكوين رؤية أكثر قوة.

OUTLINE

Definition of Data Science

Data Science as an multi-disciplinary field

Data Science Life Cycle

Data Science Tasks

Data Science Tools

DATA SCIENCE TASKS

In general Data Science tasks can be classified into two categories:

Descriptive tasks characterize the general properties of the data.

Predictive tasks perform deduction on the current data in order to make predictions.

بشكل عام ، يمكن تصنيف مهام علوم البيانات إلى فئتين:
تميز المهام الوصفية الخصائص العامة لـ البيانات.
تقوم المهام التنبؤية بالخصم على البيانات الحالية لعمل تنبؤات.

DATA SCIENCE TASKS

Most famous data Science tasks:

Descriptive

Clustering

Detect natural groupings

Outlier detection

Detect anomalies

Affinity Analysis

Co-occurrence patterns

Predictive

Classification

Predict a category

Regression

Predict a value

Recommendation

Predict a preference

DATA SCIENCE TASKS

CLASSIFICATION

Classification is used for predictive Science tasks.

The input data for predictive modeling consists of two types of variables:

- The first is explanatory variables , which define the essential properties of the data, and
- The second is one target variables , whose values are to be predicted. Classification is used to predicate the value of discrete targetvariable.

يستخدم التصنيف لمهام العلوم التنبؤية.


تتكون بيانات الإدخال للنمذجة التنبؤية من نوعين
من المتغيرات:

الأول هو المتغيرات التفسيرية التي تحدد الأساسي
خصائص البيانات و

والثاني هو أحد المتغيرات المستهدفة ، والتي يمكن التنبؤ بقيمها. يستخدم التصنيف لتحديد قيمة متغير الهدف
المنفصل.

DATA SCIENCE TASKS

CLASSIFICATION




DATA SCIENCE TASKS

CLASSIFICATION



Insurance Risk Assessment

Age	Car Type	Risk
23	family	High
17	sports	High
43	sports	High
68	family	Low
32	truck	Low
20	family	High



DATA SCIENCE TASKS

REGRESSION

Similar to classification, except we are trying to predict the value of a variable (e.g. amount of purchase), rather than a class (e.g. purchaser or non-purchaser)

على غرار التصنيف ، باستثناء أننا نحاول التنبؤ بقيمة متغير (مثل مبلغ الشراء) ، بدلاً من فئة (مثل المشتري أو غير المشتري)

	Cycle time (ns) MYCT	Main memory (KB)		Cache (KB) CACH	Channels		Performance PRP
		Min. MMIN	Max. MMAX		Min. CHMIN	Max. CHMAX	
1	125	256	6000	256	16	128	198
2	29	8000	32000	32	8	32	269
3	29	8000	32000	32	8	32	220
4	29	8000	32000	32	8	32	172
5	29	8000	16000	32	8	16	132
...							
207	125	2000	8000	0	2	14	52
208	480	512	8000	32	0	0	67
209	480	1000	4000	0	0	0	45

DATA SCIENCE TASKS

REGRESSION

تراجع

Examples:

- Predicting sales amounts of new product based on advertising spending.
- Predicting wind velocities as a function of temperature, humidity, air pressure, etc.

توقع كميات مبيعات منتج جديد بناءً على الإنفاق الإعلاني.
توقع سرعات الرياح كدالة في درجة الحرارة والرطوبة وضغط الهواء وما إلى ذلك.

DATA SCIENCE TASKS

RECOMMENDATION SYSTEMS

Recommendation Systems (RS) help to match users with items

- Ease information overload
- Sales assistance (guidance, advisory, persuasion,...)


تساعد أنظمة التوصيات (RS) على مطابقة المستخدمين بالعناصر
سهولة التحميل الزائد للمعلومات

مساعدة المبيعات (إرشاد ، استشاري ، إقناع ، ...)

DATA SCIENCE TASKS

RECOMMENDATION

SYSTEMS




Recommender Systems: An Introduction

by [Dietmar Jannach](#), [Markus Zanker](#), [Alexander Felfernig](#), [Gerhard Friedrich](#)

AVERAGE CUSTOMER RATING:

☆☆☆☆☆ ([Be the first to review](#))



Registrieren, um sehen zu können, was deinen Freunden gefällt.

FORMAT:

Hardcover

NOOKbook (eBook) - not available

[Tell the publisher you want this in NOOKbook format](#)

NEW FROM BN.COM

~~\$65.00~~ List Price

\$52.00 Online Price
(You Save 20%)

Add to Cart

NEW & USED FROM OUR

New starting at **\$56.46** (You Save 13%)
Used starting at **\$51.98** (You Save 21%)

See All Prices

[Table of Contents](#)

Customers who bought this also bought



DATA SCIENCE TASKS

RECOMMENDATION SYSTEMS



Jobs you may be interested in ^{Beta}

[Email Alerts](#) | [See More »](#)



Technical Sales Manager - Europe
Thermal Transfer Products - Home office



Senior Program Manager (f/m)
Johnson Controls - Germany-NW-Burscheid



Groups You May Like

[More »](#)



Advances in Preference Handling
[Join](#)



FP7 Information and Communication Technologies (ICT)
[Join](#)



The Blakemore Foundation
[Join](#)




DATA SCIENCE TASKS

CLUSTERING

Finds **groups of data points** (clusters) so that data points that belong to one cluster are more similar to each other than to data points belonging to different cluster.

يبحث عن مجموعات من نقاط البيانات (المجموعات) بحيث تكون نقاط البيانات التي تنتمي إلى مجموعة واحدة أكثر تشابهًا مع بعضها البعض من نقاط البيانات التي تنتمي إلى مجموعة مختلفة.



Find “natural” grouping of instances given un-labeled data

Document Clustering:

- **Goal:**
 - To find groups of documents that are similar to each other based on the important terms appearing in them.
- **Approach:**
 - Identify frequently occurring terms in each document.
 - Form a similarity measure based on the frequencies of different terms.
 - Use it to cluster the documents.
- **Gain:**
 - Information Retrieval can utilize the clusters to relate a new document or search term to clustered documents.

تجميع المستندات:
هدف:
للبحث عن مجموعات من المستندات
التي تشبه كل منها
أخرى بناءً على المصطلحات المهمة
التي تظهر فيها.
مقاربة:
حدد المصطلحات المتكررة في كل
وثيقة.
كوّن مقياس تشابه بناءً على تكرارات
المصطلحات المختلفة.
استخدمه لتجميع المستندات.
ربح:
يمكن أن يستخدم استرداد المعلومات
المجموعات لربط مستند جديد أو
مصطلح بحث بمستندات مجمعة.

DATA SCIENCE TASKS

OUTLIER ANALYSIS

Discovers data points that **are significantly different** than the rest of the data. Such points are known as **anomalies** or **outliers**.


Applications:

- Credit Card Fraud Detection

يكتشف نقاط البيانات التي تختلف اختلافاً كبيراً عن باقي البيانات. تُعرف هذه النقاط بالشذوذ أو القيم المتطرفة.

التطبيقات:

كشف الاحتيال على بطاقة الائتمان



OUTLINE

Definition of Data Science

Data Science as an multi-disciplinary field

Data Science Life Cycle


Data Science Tasks

Data Science Tools

DATA SCIENCE TOOLS CHAINING TOOLS FOR DATASCIENCE أدوات علوم البيانات

أدوات التسلسل لعلم البيانات

- Use the right toolset in different stages
- استخدم مجموعة الأدوات المناسبة في مراحل مختلفة



DATA SCIENCE TOOLS FOR OBTAINING DATA للحصول على البيانات

Database Management: MySQL, PostgreSQL, MongoDB

Retrieving Unstructured Data: text, videos, audio files, documents

Distributed Storage: Hadoops, Apache Spark

Hadoop is an open-source framework that allows to store and process big data in a distributed environment across clusters of computers using simple programming models.

إدارة قواعد البيانات: MySQL و PostgreSQL و MongoDB

استرجاع البيانات غير المهيكلة: نصوص ، فيديوهات ، ملفات صوتية ، مستندات

التخزين الموزع: Hadoops ، Apache Spark

Hadoop هو إطار عمل مفتوح المصدر يسمح بتخزين ومعالجة البيانات الضخمة في بيئة موزعة عبر مجموعات من أجهزة الكمبيوتر باستخدام نماذج برمجة بسيطة.

DATA SCIENCE TOOLS FOR CLEANING DATA

أدوات علوم البيانات لتنظيف البيانات

Scripting language: Python, R, SAS

Tools: RapidMiner ,Weka

Distributed Processing: Hadoop, Map Reduce

لغة البرمجة: Python ،R ،SAS Tools: RapidMiner ،Weka

المعالجة الموزعة: Map Reduce ،Hadoop

DATA SCIENCE TOOLS FOR DATA EXPLORATION

أدوات علوم البيانات لاستكشاف البيانات

Python: Numpy, Matplotlib, Pandas, Scipy R: GGplot2, Dplyr

SpreadSheets: Excel

Data Visualization: Tableau, Qlikview

DATA SCIENCE TOOLS **FOR FEATUREENGINEERING** أدوات علوم البيانات للهندسة المميزة

Languages: Python, R

Tools: FeatureTools, Rapidminer

**Machine Learning: Azure Machine Learning , Amazon
Machine Learning**

DATA SCIENCE TOOLS FOR **MODELING** أدوات علم البيانات للنمذجة

Machine Learning Libraries: Python (Sci-kit Learn) / R (CARET)

Statistics: SPSS, SAS

Tools: Rapidminer, Weka, MLBase

DATA SCIENCE TOOLS **DATA VISUALIZATION** تصور البيانات أدوات علوم البيانات

Python: Numpy, Matplotlib, Pandas, Scipy

R: GGplot2, Dplyr

SpreadSheets: Excel

Data Visualization: Tableau, Qlikview

Communication: Presenting/Speaking & Reporting/Writing